Løsningforslag for obligatorisk innlevering 1 – $$\operatorname{INF}2820$$

February 27, 2017

Oppgave 1


a) $LM = \{abbba, aba, abbbbba, abcbba, abca, cbba, ca\}$ b) $ML = \{bbaab, bbaabbb, bbaabc, bbac, aab, aabbb, aabc, ac\}$ c) $\{ac, ab, aaabbb\} \subseteq M^*L$ d)

 $\{\epsilon, ac\} \subseteq (ML)^*$


e) $LN = \emptyset$ LP = L

Oppgave 2


a)



b)



c)



Merk at vi har lagt til en trap-state før vi finner komplementet. Vi tegner vanligvis ikke denne tilstanden fordi det kompliserer diagrammet unødig, men antar heller at den er tilstede.

d)

 $\{abc, acb, bac, aaab, aaba, abaa, baaa\} \subseteq L1$

Oppgave 3

a)

$$(a+b+c)^*bbb(a+b+c)^*$$

b)

$$(a+c)^*((bb+b)(a+c)(a+c)^*)^*(bb+b+\epsilon)$$

c)

$$((a+c)^*(b(a+c)^*b(a+c)^*b(a+c)^*)^*) + ((c+b)^*(a(c+b)^*a(c+b)^*)^*)$$

Fordi0er delelig på et hvert tall så skal også strenger hvor antall a'er eller b'er er 0også være med.

Oppgave 4

```
import re
def beskriver(regeksp, ord):
    reg = "^("+regeksp+")$"
    if re.search(reg, ord):
       return True
    else:
       return False
def test(regex, correct, incorrect):
    print("Testing '{}'".format(regex))
    for word in correct:
        if not beskriver(regex, word):
            print("Should have been recognized: '{}'".format(word))
    for word in incorrect:
        if beskriver(regex, word):
            print("Should not have been recognized: '{}'".format(word))
# 4a
regex_a = "(a|b|c)*bbb(a|b|c)*"
correct_a = ("bbb", "cbabbbacba")
incorrect_a = ("b", "bbacabbca")
test(regex_a, correct_a, incorrect_a)
# 4b
regex_b = "(a|c)*((bb|b)(a|c)(a|c)*)*(bb|b|)"
correct_b = ("abba", "abcabcbb")
incorrect_b = ("bbb", "babcabbcbbb")
test(regex_b, correct_b, incorrect_b)
regex_c = "((a|c)*(b(a|c)*b(a|c)*b(a|c)*)*)|((c|b)*(a(c|b)*a(c|b)*)*)"
correct_c = ("", "c", "a", "b", "aabccbbaabbcbacabcbcccaabbb")
incorrect_c = ("abaab", "aabba")
test(regex_c, correct_c, incorrect_c)
Oppgave 5
a)
>>> pyt_raw = open("Python_INF2820_v2017.txt").read()
```

```
b)
>>> pyt_words1 = pyt_raw.split()
>>> pyt_words2 = nltk.word_tokenize(pyt_raw)
```

Når vi bruker split() så blir tegnsetting hengende fast i ordene og og vi får strenger som "INF2820,". Derimot når vi bruker tokenisering så blir tegnsetting skilt ut i egen tokens og vi får da "INF2820" og ",". Noen ganger skiller tokeniseringen for mye, f.eks. vil "'http://www.uio.no" bli tokenisert til ["http", ":", "//www.uio.no"].

```
c)
>>> pyt_low = [w.lower() for w in pyt_words2]

d)
>>> forekomster = [w for w in pyt_low if re.search("[xøå]", w)]
>>> print(len(forekomster))
60

e)
>>> print(len(set(forekomster)))
23

f)
with open("norske.txt", "w") as f:
   for w in set(forekomster):
       f.write("{}\n".format(w))
```

Oppgave 6

a)

Her tar vi forbehold om at vi kun er ute etter stier som starter med "/" og at det hver "/" må være adskilt med i det minste ett symbol. For enkelthets skyld antar vi også at en sti ikke kan inneholde mellomrom.

```
path_regex = "(/[^/]+)+/?"

b)

def replace_tokens(tokens):
   path_regex = "^(/[^/ \n]+)+/?$"
   num_regex = "^\d+(\.\d+)?$"

replaced = []

for token in tokens:
```